

Digital Home Platform

环境感知 · 推理计算 · AI 驱动的家庭物联系统



Presenter:

Wenlei

不依赖穿戴设备，让AI融入物理世界

为什么做这件事？

灵感来源

- MIT Media Lab: Sixth Sense (2009)
- Microsoft RoomAlive 空间投影
- 超越 HoloLens 与 Mesh 的激进架构

"不依赖穿戴设备，让 AI 真正融入物理世界"



环境感知

让 AI 真正"看见"物理空间，而不只是回答文字问题



无设备交互

不依赖手机、手环、AR眼镜，将输出叠加到真实桌面



本地优先

推理在本地 GPU 完成，数据不出家门，极低延迟

典型使用场景



找东西

用户："我的钥匙在哪里？"

摄像头拍照 → 模型识别 →
指向钥匙的回复



谁来过

用户："谁进来了？"

InsightFace 识别注册人员 →
记录时间与地点轨迹




遥控器

操作：语音触发

ESP32 麦克风 → Whisper 识别 → LLM 回复 → 喇叭

借助多感知设备的介入，实现更多的场景应用

系统架构



推理引擎模型栈

YOLO26L (目标检测)

- 实时物体识别：标签 + 置信度 + 位置
 - 用途：物品定位、人物出现记录
- [速度] GPU: <100ms/帧 | CPU: ~500ms/帧

CLIP ViT-B/32 (物品识别)

- 零样本识别 + 用户自定义物品注册
 - 支持多角度滚动平均 Embedding
- [存储] 512维向量直接存入 PostgreSQL

InsightFace buffalo_l (人脸识别)

- 置信分级：≥0.75 高置信，低置信自动学习
 - Sample Count 累积自动更新 Embedding
- [路线] GPU: ONNX CUDA | CPU: ONNX CPU

Whisper + Kokoro TTS (语音)

- faster-whisper 极速语音识别
 - Kokoro-82M 轻量级本地语音合成
- [路线] 全本地推理，不依赖外部服务 (待完成)

控制界面 (Vision Platform UI)



1. Live 实时预览

实时摄像头流，CSS Transform 方向控制，无延迟翻转与旋转。



2. History 历史记录

检测时间线，缩略图+标签。支持按设备、物品多维度联合筛选。



3. Items 物品注册

自定义物品训练，拖拽上传多角度图片，生成 CLIP Embedding。



4. Faces 人脸库

人脸特征提取与库管理，识别阈值测试，未知人员自动收录。



5. Devices 设备管理

管理所有接入节点，检测在线 Ping 状态，支持一键 OTA 固件升级。



6. System 系统状态

监控服务健康度、GPU 显存占用、模型加载状态及存储配额。

本地优先部署方案

GPU 生产路线

- 目标硬件：GPU
- YOLO 模型：YOLO26L (高精度)
- 推理速度：< 100ms / 帧
- 镜像/存储：~8GB, 外部 PG 数据库
- 适用场景：主力生产、低延迟要求

VS

CPU 降级路线

- 目标硬件：x86 / mini PC
- YOLO 模型：YOLO26N (轻量)
- 推理速度：~500ms / 帧
- 镜像/存储：1.4GB, 内嵌 PG 数据库
- 适用场景：备用降级、轻量部署

本地模型优先的调用策略

1. 优先 本地 推理



2. 切云端模型


Language UI: OpenClaw

角色与定位

- OpenClaw 是运行在 Mac 上的 AI 助手客户端
- 通过 **Skill** 系统 将自然语言指令转化为硬件操作
- 隐私保护：照片不经过 远端服务，仅在本地图完成推理，Skill 只接收文字结果

通过 Skill 进行服务调用

摄像头感知、物品定位、历史搜索



多设备分组和物品注册

注册新物品

物品名称, 例如: 钥匙

描述 (可选)

点击或拖拽图片 (支持多选)

多角度拍摄效果更好 · 支持 JPG/PNG

+ 注册物品

已注册物品 (4)

标签	描述	样本数	注册时间	操作
桌面吸尘器	—	3 张	2026/4/29	删除
我的第一个手机	OPPO FindX8s	16 张	2026/4/17	删除
我的茶杯	—	3 张	2026/4/17	删除
我第二个手机	OPPO FindX5 Pro	7 张	2026/4/17	删除

Digital Home

Platform 20260419

Live

Devices

Audio

History

Items

Faces

API

API Bindings

刷新

选择设备能力

全部设备 显示全部端点

端点说明

POST /detect/group/{tag}	对该 Tag 下全部设备同时抓帧, 运行 YOLO 目标检测 + CLIP 自定义物品匹配。返回每台设备的 bounding box、标签、置信度及标注图路径。
POST /describe/group/{tag}	轻量版检测, 不生成标注图。仅返回文字描述 (如 "Detected: person, laptop") 和自定义物品匹配结果, 适合轮询或文本通知场景。
POST /capture/group/{tag}	仅抓帧保存, 不做任何推理。返回各设备的图片存储路径, 用于截图归档或后续离线分析。
POST /detect/{name-or-mac}	对指定设备单独抓帧并完整检测, 无需上传图片。支持设备名 (推荐, 如 desk-cam-01) 或 MAC 地址, 不区分大小写。适合脚本定时触发或外部服务针对某台摄像头的独立请求。
POST /detect upload	上传图片文件进行检测 (form-data: file、可选 camera_ip / device_mac)。返回 detections 列表和标注图, 适合 ESP32 直接 HTTP POST 原始帧。
POST /detect/all	对所有已注册设备 (含 stream_url) 同时抓帧并检测, 不受 Tag 限制。适合一次性全局扫描。
GET /search	查询检测历史。支持参数: ?label=person (按标签过滤)、?limit=50 (条数)、?device_mac=... (按设备过滤)。
POST /face/identify upload	人脸识别, 上传图片 (form-data: file), 返回匹配姓名、置信度及是否触发自适应学习。
POST /audio/infer	接收 ESP32 上传的 PCM 音频 (16kHz 16-bit), 处理后返回音频响应。用于语音交互流程。
POST /speak	从后端主动向 ESP32 推送音频。请求体: PCM 二进制数据。需通过 X-Device 头指定目标设备。
POST /record	远程触发 ESP32 录音 (5秒)。替代 BOOT 物理按键, 录音完成后自动上传到 /audio/infer。

TAG 端点绑定 3 个 TAG

在 Devices 页为设备设置 Tag, 同 Tag 设备自动归组。点击路径 chip 启用或禁用该端点。

Tag	设备	检测 (YOLO)	描述 (轻量)	截图	操作
front	desk-cam-02	POST /detect/group/front	POST /describe/group/front	POST /capture/group/front	复制 测试
side	desk-cam-01	POST /detect/group/side	POST /describe/group/side	POST /capture/group/side	复制 测试
test	desk-audio-03	POST /detect/group/test	POST /describe/group/test	POST /capture/group/test	复制 测试

GPU 4090

Digital Home Platform 的意义

1. 技术探索

将计算机视觉、自然语言处理、边缘计算融合在家庭环境中，验证"环境感知 AI"的可行性。

2. 交互范式

不依赖屏幕和手持设备，通过空间投影将 AI 的判断叠加到物理世界——这是 AR 的另一种路径。

3. 开放架构

开源 monorepo，模块化设计，GPU/CPU 双路线，可扩展到任意家庭场景。

" 我们的愿望是让 AI 真正 '住' 在你的家里。 "

github.com/wenlei/vision-platform